

Análisis de Series de Tiempo Aplicado a la

Generación Eléctrica Mensual de Argentina

(2015 - 2023)

Curso: Análisis de Series de Tiempo I (02MIA2026)

Programa: Especialización en Inteligencia Artificial – UBA, FIUBA

Docente: Camilo Argoty

Alumnos: Gustavo Rivas · Carlos Rivas · Fermín Rodríguez

**Especialización en
Inteligencia Artificial**

Facultad de Ingeniería – UBA

1. De qué se trata el trabajo y qué queremos responder
2. Los datos: de dónde vienen y cómo son
3. Qué patrones encontramos (tendencia, estacionalidad)
4. Los modelos que probamos: ARIMA, SARIMA, Holt-Winters y Prophet
5. Cómo comparamos los modelos y cuál ganó
6. Validación: ¿el modelo ganador está bien armado?
7. Un extra: medir la volatilidad con GARCH
8. Pronóstico para 2024 y conclusiones

¿Qué queremos responder?

¿Qué modelo predice mejor la generación eléctrica mensual de Argentina: ARIMA, SARIMA, Holt-Winters o Prophet? ¿Y qué tan importante es la fuerte estacionalidad anual –con picos en verano e invierno– para el resultado?

En otras palabras, queremos lograr tres cosas:

- **Entender cómo se mueve la generación eléctrica:** ¿tiene tendencia? ¿se repite un patrón cada año?
- **Probar cuatro modelos distintos** y comparar qué tan bien predicen, apoyándonos en pruebas estadísticas formales para justificar cada decisión (no "a ojo").
- **Elegir el mejor modelo** y usarlo para proyectar la generación eléctrica de 2024, con un rango de confianza.

Dos formas distintas de "mirar" una serie

- **Familia 1 – ARIMA / SARIMA:**

- Necesitan que la serie sea "estable" (estacionaria): sin tendencias raras ni cambios de comportamiento en el tiempo
- Si no lo es, se la transforma (diferenciando) hasta que lo sea
- Aprenden la dependencia entre un mes y los anteriores

- **Familia 2 – Holt-Winters / Prophet:**

- No exigen esa estabilidad previa
- Separan directamente la serie en "nivel", "tendencia" y "estacionalidad", y los van actualizando mes a mes

Nuestra hipótesis

Como la generación eléctrica argentina tiene un patrón estacional muy marcado, esperamos que los modelos que lo capturan explícitamente (SARIMA, Holt-Winters, Prophet) le ganen por bastante a un modelo que no lo tiene en cuenta (ARIMA).

Además, notamos que algunos meses son más "volátiles" que otros, así que sumamos un modelo extra (GARCH) para medir esa variabilidad.

De dónde vienen nuestros datos

- **Dataset público de Kaggle:** "Electricity Production Dataset" (autor: sazidthe1)
 - Trae datos mensuales de generación eléctrica de 48 países, entre 2010 y 2023
 - Nos quedamos solo con **Argentina** y con la generación neta total ("Net Electricity Production")
 - Resultado: una serie de **108 meses**, de enero 2015 a diciembre 2023
- Después de filtrar, la serie con la que trabajamos es muy simple:

Columna	Qué significa
Fecha (mes)	Un dato por mes, de enero de 2015 a diciembre de 2023
Generación (GWh)	Cuánta electricidad se generó en Argentina ese mes, en gigavatios-hora


¿Los datos están "limpios"?

- No hay valores faltantes
- No falta ningún mes: la serie está completa y es continua
- No detectamos valores atípicos (outliers)
- **Conclusión:** no hicieron falta correcciones, la serie está lista para analizarse tal cual.

Estadístico	Valor (GWh)
Cantidad de meses	108
Promedio	33.811
Desvío estándar	3.058
Mínimo	25.656
Percentil 25	31.450
Mediana	33.508
Percentil 75 / Máximo	35.881 / 40.883


La variación entre meses representa solo **~9% del promedio**: es decir, la serie no "salta" de forma errática, gran parte de ese movimiento se explica por la época del año (estacionalidad).

Así se ve la serie completa





- **Nivel promedio:** ~33.800 GWh por mes
- No hay una **tendencia** clara de crecimiento o caída en los 9 años
- Pero sí hay una **baja marcada en los últimos años:** -11,6% en 2022 y -19,3% en 2023
- Se repite todos los años el mismo patrón: **sube en verano e invierno**
- Se ven caídas puntuales en momentos puntuales (ej. **pandemia 2020**)

¿Cuánto creció (o cayó) cada año?



Año	Variación
2015	+0,07 %
2016	-2,93 %
2017	-5,38 %
2018	-14,06 %
2019	+0,87 %
2020	+2,10 %
2021	-0,46 %
2022	-11,64 %
2023	-19,26 %



Separando la serie en sus "piezas"



Toda serie se puede pensar como **Tendencia + Estacionalidad + Residuo** (esquema "aditivo", izquierda) o como **Tendencia × Estacionalidad × Residuo** ("multiplicativo", derecha).

En nuestro caso, ambos esquemas dejan un residuo muy parecido (~1.550 GWh), así que probamos las dos variantes más adelante con Holt-Winters.



El patrón que se repite cada año



Izquierda: el promedio de generación por mes muestra dos picos –verano (enero/febrero, por el aire acondicionado) e invierno (junio/julio, por calefacción)– con valles en las épocas de transición.

Derecha: suavizando la serie con un promedio móvil de 12 meses, se ve un nivel estable entre 2015 y 2021, y la caída sostenida de 2022-2023.

¿Quedó algo sin explicar?



Chequeo	Resultado	p-valor
¿Son normales?	Sí	0,184
¿Son estables?	Sí	0,000

Lo que sobra después de sacar tendencia y estacionalidad se comporta como "ruido": no tiene patrones escondidos. Buena señal.

¿La serie es "estable"? (ADF y KPSS)

- Para usar ARIMA/SARIMA, la serie tiene que ser "estable" en el tiempo (estacionaria)
- Usamos **dos pruebas que se complementan**: si las dos coinciden, la conclusión es más confiable

Versión de la serie	Prueba 1 (ADF)	Prueba 2 (KPSS)	¿Es estable?
Serie original	No pasa	Pasa	No del todo
Con 1 diferencia simple ($d=1$)	Pasa	Pasa	Sí
Con 1 diferencia estacional ($D=1$)	No pasa	Pasa	No del todo
Con ambas diferencias ($d=1$ y $D=1$)	Pasa	Pasa	Sí, la mejor opción


Conclusión: hace falta aplicar las dos diferenciaciones –una simple y una estacional– para que la serie quede "estable". Por eso el SARIMA que construimos usa **$d=1$ y $D=1$** .

Los 4 modelos que vamos a comparar

Modelo	¿Qué lo distingue?	¿Tiene en cuenta la estacionalidad?
ARIMA	El más simple: solo mira los valores recientes. Nuestro "punto de partida"	No
SARIMA	Como ARIMA, pero agrega el ciclo de 12 meses	Sí
Holt-Winters (aditivo)	Suaviza nivel, tendencia y estacionalidad como cantidades fijas	Sí
Holt-Winters (multiplicativo)	Igual, pero la estacionalidad es un % del nivel	Sí
Prophet	Modelo de Meta/Facebook, ajusta tendencia y estacionalidad automáticamente	Sí (anual)


Para que la comparación sea justa: entrenamos todos los modelos con los datos de **2015-2022**, y los evaluamos prediciendo **2023** (12 meses que ningún modelo vio antes).

Modelo 1: ARIMA – el punto de partida





- Mira solo el **mes anterior** y los **errores recientes** para predecir el siguiente
- No sabe nada de "verano" o "invierno": **no tiene componente estacional**
- Por eso esperamos que sea el que **peor prediga** frente a un patrón tan estacional
- Sirve como **"piso"**: si otro modelo no le gana a este, no vale la pena usarlo

Modelo 2: SARIMA – ARIMA + estacionalidad




- Es ARIMA, pero además **compara cada mes con el mismo mes del año anterior**
- Las dos diferenciaciones (**d=1 y D=1**) que vimos antes están incorporadas acá
- Es el modelo "**candidato natural**" para una serie tan estacional como la nuestra
- Esperamos que sea **de los mejores**, ya que ataca directamente el patrón anual

Modelo 3: Holt-Winters – suavizado inteligente




- Separa la serie en 3 "piezas" –**nivel, tendencia y estacionalidad**– y las va actualizando mes a mes a medida que llegan nuevos datos
- **Versión aditiva** (izquierda): la estacionalidad suma/resta siempre la misma cantidad de GWh
- **Versión multiplicativa** (derecha): la estacionalidad es un porcentaje del nivel actual

Modelo 4: Prophet – el de Meta/Facebook



- Divide la serie en **tendencia + estacionalidad**, igual que los anteriores, pero ajusta todo **automáticamente**
- Usa una técnica matemática (**series de Fourier**) para representar la estacionalidad anual
- No necesitamos elegir tantos parámetros a mano ni verificar estacionariedad
- Lo incluimos como cuarto modelo para tener un punto de comparación **"moderno"** y de uso muy extendido en la industria

¡El momento de la verdad! ¿Quién ganó?





Modelo	Error promedio (MAPE)
SARIMA	8,15 %
Holt-Winters (multiplicativo)	9,02 %
Holt-Winters (aditivo)	9,32 %
Prophet	11,61 %
ARIMA	13,01 %

El MAPE es el error promedio en porcentaje: "en promedio, el modelo se equivoca un X% del valor real". Cuanto más bajo, mejor.


Ganó SARIMA con 8,15% de error. La diferencia con ARIMA (13,01%) muestra cuánto aporta modelar la estacionalidad.

Mirando de cerca al ganador: SARIMA



La línea de predicción de SARIMA **sigue de cerca a la línea real**, incluyendo los picos estacionales. Las mayores diferencias aparecen en los meses donde la caída de 2023 fue más fuerte.

¿SARIMA está bien armado?



Horizonte	¿Hay patrones sin explicar?	p-valor
6 meses	No	0,946
12 meses	No	0,125
18 meses	No	0,302
24 meses	No	0,639

Esta prueba (**Ljung-Box**) chequea si quedó algún patrón sin explicar en lo que el modelo no pudo predecir. En todos los horizontes –incluso a 12 y 24 meses, los "ciclos" anuales– la respuesta es "no": **SARIMA capturó bien tanto el corto plazo como el ciclo anual.**

¿Y si lo elegía la computadora?


Configuración SARIMA	Puntaje (AIC, menor = mejor ajuste)
(1,1,1)(0,1,1,12) ← elegido por la PC	1244,08
(1,1,1)(1,1,1,12) ← el nuestro	1245,97
(0,1,1)(0,1,1,12)	1248,39
(0,1,1)(1,1,1,12)	1250,38
(1,0,1)(0,1,1,12)	1261,68

Configuración	Error (MAPE) prediciendo 2023
Elegida por la PC	9,47 %
La nuestra (manual)	8,15 %

Probamos también una **búsqueda automática** que recorre muchas combinaciones y elige la de mejor "puntaje" interno (AIC).

La diferencia de puntaje es mínima, pero a la hora de predecir 2023 de verdad, **nuestra configuración elegida "a mano" predijo mejor** (8,15% vs. 9,47%). **Moraleja:** un buen puntaje interno no garantiza el mejor pronóstico real, por eso siempre hay que validar contra datos reales.

Bonus: ¿qué tan "nerviosa" es la serie?




Parámetro	¿Qué mide?	¿Es relevante?
ω	Nivel "normal" de volatilidad	Sí
α (shocks)	Reacción a una sorpresa puntual	No tanto
β (memoria)	Cuánto dura un período movido	Sí

Todos los modelos anteriores predicen el valor promedio. **GARCH va un paso más allá:** predice qué tan "ancho" debería ser el margen de error mes a mes.

Encontramos que **los períodos movidos tienden a continuar un tiempo** (hay "memoria"), pero un shock puntual no dispara por sí solo un período de alta volatilidad.

En la práctica: permite dar intervalos de confianza más realistas, más anchos cuando "está movido" y más angostos cuando está tranquilo.

¿Y qué esperamos para 2024?



Mes	Pronóstico	Mínimo esperado	Máximo esperado
Enero	35.332	31.161	39.503
Febrero	29.570	24.767	34.373
Marzo	33.997	28.937	39.057
Junio	32.933	27.512	38.353
Julio	32.693	27.182	38.203
Diciembre	30.696	24.772	36.619

Valores en GWh. Tabla resumida (6 de 12 meses) – el detalle completo está en el informe.

Lo que aprendimos (parte 1)

- **Respondiendo la pregunta inicial:** SARIMA fue el mejor (8,15% de error), y la estacionalidad anual resultó ser **el factor más importante** para predecir bien.
- El orden final fue: **SARIMA**, después **Holt-Winters** (~9%), después **Prophet** (11,6%) y por último **ARIMA** (13%) – confirmando que cuanto mejor se modela la estacionalidad, mejor se predice.
- Entre las dos versiones de Holt-Winters, **la multiplicativa fue apenas mejor** (9,02% vs. 9,32%) – una diferencia pequeña, esperable según lo que ya habíamos visto en la descomposición.
- La **fuerte caída de 2022-2023** fue el principal "dolor de cabeza" para todos los modelos: ninguno podía anticipar ese quiebre sin información externa (ej. actividad económica).

Lo que aprendimos (parte 2)

- El **"piloto automático"** (selección por AIC) **no siempre gana**: nuestra configuración elegida a mano predijo mejor en datos reales (8,15% vs. 9,47%).
- **GARCH** mostró que la volatilidad "tiene memoria": los períodos movidos tienden a continuar, lo que permite dar márgenes de error más realistas.
- Validamos que SARIMA no solo ganó en precisión, sino que **está bien especificado**: no deja patrones sin explicar en sus errores.
- **Aprendizaje general**: ningún indicador por sí solo (ni el puntaje interno, ni el error de predicción, ni las pruebas de residuos) alcanza – hay que mirar **los tres juntos** para elegir con confianza.

Muchas gracias

Preguntas y discusión

Gustavo Rivas · Carlos Rivas · Fermín Rodríguez

Análisis de Series de Tiempo (02MIA2026) – Especialización en IA, UBA FIUBA